



Relatório Projeto: Segmentasaun Kliente uza K-Means no PCA

1. Deonisia da Costa
2. Ernia Hornai
3. Julito Gonsalves
4. Oscar Cardoso

Departamentu Teknika Informatika

Agusto 6, 2026

1 Introdusaun

Iha mundu komérsiu no marketing modernu, hatene karakterístika, konduta, no toman gastu kliente nian mak sai elementu xave ba susesu no konkursu negósiu nian. Ho análise dadus kliente nian ne'ebé sistemátiku, empreza no organizasaun sira bele foti desizaun estratéjika ne'ebé efektivu hodi fó atensaun no servisu di'ak liu ba grupu kliente espesífiku.

Motivasaun prinsipál husi projetu ne'e mak atu dezenvolve no kria sistema automatizadu ida ne'ebé integra algoritmu *Unsupervised Machine Learning*, partikularmente *K-Means Clustering* no *Principal Component Analysis (PCA)*. Sistema ne'e desenhado atu fasilita análista marketing sira atu fahe dataset kliente ba kategoria ka segmentu oioin ho lalais, efisiente, no akuradu. Liuhusi dalan ne'e, empreza labele de'it hasae efisiénsia kampanha produktu nian ba tarjetu ne'ebé loos, maibé mós bele optimiza rendimentu finanseiru no kria relasaun ne'ebé metin liu ho kliente iha tempu naruk.

2 Deskrisaun Problema

Negósiu no empreza barak iha mundu modernu ne'e infrenta difikuldade no desafio boot atu fahe kliente ba kategoria ne'ebé loos bazeia ba rendimentu anual no pontu gastu (*spending score*). Desafiu ne'e mosu tanba volume dadus kliente nian ne'ebé boot, dinamiku, no kompleksu tebes, nune'e susar ba análista sira atu halo prosesu manual. Iha sorin seluk, sinál husi kliente sira ne'ebé potensial loos ka kliente VIP dala barak la hetan identifikasaun ne'ebé di'ak no lalais. Kondisaun ne'e bele afeta direta estratejia promosaun ka kampanha marketing ne'ebé la tuir tarjetu, fó gasta osan ba buat ne'ebe la loos ka hasai osan arbiru deit, no hamenus rendimentu empreza nian. Tan ne'e, presiza tebes

atu solusiona problema ne'e liuhusi implementasaun modelu no algoritmu *Machine Learning* nian ne'ebé bele automatika prosesu segmentasaun kliente ho akuradu no efisiente.

3 Objektivu

Objetivu prinsipál no espesífiku husi projetu ne'e fahe ba parámetru tuir mai ne'e:

- 1. Dezenvolve no Implementa Modelu K-Means:** Dezenvolve no aplika modelu segmentasaun kliente bazeia ba *Unsupervised Machine Learning* hodi uza algoritmu *K-Means Clustering* ho determinasaun total cluster óptimu $K = 4$. Koko atu agrupa kliente tuir sira nia rendimentu annual no pontu gastu ho efisiente.
- 2. Redusaun Dimensaun ho PCA:** Aplika *Principal Component Analysis (PCA)* hodi transforma dadus multidimensional kompleksu sai ba espasu koordenada 2D, hodi nune'e bele maximiza variasaun dadus no fasilita vizualizasaun gráfiku scatter plot sen lakon informasaun ruma.
- 3. Dezenvolvimentu Protótipu Aplikasaun:** Harii protótipu aplikasaun interativu nian hodi integra modelu treinadu, fó facilidade ba análista ka emprezáriu sira hatama dadus no halo prediksaun automatika ba kategoria kliente foun.
- 4. Avaliasaun Kualidade Modelu:** Avalia kualidade no validas husi grupu (cluster) ne'ebé harii ona hodi uza *Silhouette Score*, hodi garante katak separasaun entre grupu kliente sira iha kualidade ne'ebé di'ak.

4 Metodolojia

Projéto ne'e uza abordagem *Unsupervised Machine Learning* hodi fahe no analiza dados kliente nian.




Figure 1: Ilustrasaun konseptual ba Unsupervised Learning no Clustering

Algoritmu prinsipal rua ne'ebé uza mak K-Means no PCA:

- K-Means Clustering

K-Means mak algoritmu *clustering* ne'ebé fahe dataset ba kluster K ne'ebé determina ona. Algoritmu ne'e serbisu hodi grupo kliente ne'ebé iha toman ka karakterístika hanesan hamutuk, no minimiza distánsia entre dados kliente ho sira nia centroid (pontu center) iha grupu ida-idak. Objetivu mak atu garante katak kluster sira iha separasaun ne'ebé di'ak.




Figure 2: Ilustrasaun prosesu K-Means Clustering no Sentroid

- Principal Component Analysis (PCA)

Hodi halo redusaun dimensaun no vizualizasaun dados kompleksu ba espasu 2D, uza *Principal Component Analysis (PCA)*. PCA buka diresaun (principal components) ne'ebé maximiza variasaun

dados, hodi nune'e bele hatudu padrão xave no facilita vizualizasaun gráfiku sem lakon informasaun importante.

5 Dataset

Dados ne'ebé uza mak `Mall_Customers.csv` ne'ebé inklui informasaun kliente nian:

- **Gender:** Jéneru kliente (Female/Male).
- **Age:** Idade kliente.
- **Annual Income (k\$):** Rendimentu anual.
- **Spending Score (1-100):** Puntu gastu kliente.

Gráfiku Elbow Method iha kraik uza hodi determina total cluster K óptimu ba dataset ne'e.




Figure 3: Gráfiku Elbow Method ba determinasaun cluster

Gráfiku Elbow hatudu liña curva ne'ebé ajuda ita identifika total cluster $K = 4$ nu'udar pontu optimal hodi halo separasaun kliente ho efeitu di'ak.

6 Data Exploration and Analysis (DEA)

Analiza dados eksploratóriu foka ba komprende relasaun inter-feature. Aplikasaun kalkula matriz ko-

relasaun Pearson r uza formula:

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y_i - \bar{y})^2}}$$

Atu komprende oinsá matriz korelasaun kalkula inter-feature iha dataset kliente nian, hanesan ezemplu uza dados amostra simples ba kliente na'in tolu ($n = 3$) ho varivel Rendimentu (X) no Puntu Gastu (Y):

- **Kliente 1:** Rendimentu $x_1 = 2$, Puntu Gastu $y_1 = 3$
- **Kliente 2:** Rendimentu $x_2 = 4$, Puntu Gastu $y_2 = 5$
- **Kliente 3:** Rendimentu $x_3 = 6$, Puntu Gastu $y_3 = 7$

Pásu dahuluk kalkula média ($\bar{x}$ no $\bar{y}$):

$$\bar{x} = \frac{2 + 4 + 6}{3} = 4, \quad \bar{y} = \frac{3 + 5 + 7}{3} = 5$$

Tuir mai kalkula formula korelasaun Pearson r :

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y_i - \bar{y})^2}}$$

Substitui val6r ba formula:

$$r = \frac{(2-4)(3-5) + (4-4)(5-5) + (6-4)(7-5)}{\sqrt{(-2)^2 + 0^2 + 2^2} \sqrt{(-2)^2 + 0^2 + 2^2}}$$

$$r = \frac{4 + 0 + 4}{\sqrt{8} \times \sqrt{8}} = \frac{8}{8} = 1.0$$

Rezultadu $r = 1.0$ hatudu katak iha relasaun direitu ne'ebé perfekto entre rendimentu no puntu gastu kliente nian.




Figure 4: Matriz Korelasaun Feature no Segmentu Kliente

Matriz korelasaun iha leten hatudu relasaun direitu no padr6es inter-feature hodi ajuda halo komprensaun ba interasaun entre variavel kliente nian molok tama fase clustering.

7 Treinu no Avaliasaun

Modelu ne'ebé treinu uza $K = 4$. Kualidade husi agrupamentu cluster iha espasu PCA medida uza *Silhouette Score*. Val6r *Silhouette Score* Jerál ba modelu ne'ebé hetan mak **0.4164**, hatudu kualidade agrupamentu ne'ebé adekuaudu no válidu.




Figure 5: Vizualizasaun Cluster K-Means no PCA ba Segmentasaun Kliente

Gráfiku scatter plot iha leten vizualiza rezultadu K-Means clustering ne'ebé transformadu ona ba espasu 2D uza PCA, hatudu ho momoos oinsá kluster haat (4) haketak malu ho separasaun ne'ebé di'ak.

8 Resultadu

Analiza no ezelesaun aplikasaun fahe dataset ba kategoria haat ($K = 4$) ho *Silhouette Score* valór **0.4164**, hatudu kualidade agrupamentu ne'ebé válidu no adekuadu. Tabela 1 hatudu sumáriu ba segmentu kliente sira:

Cluster	Kategoria	Rendimentu	Gastu
Cluster 1	Kliente VIP	Aas	Aas
Cluster 2	Kliente Standar	Normal	Moderadu
Cluster 3	Kliente Joven	Ki'ik	Aas
Cluster 4	Kliente Potensial	Moderadu	Moderadu

Table 1: Sumáriu Kategoria Cluster Kliente

Husi sumáriu iha leten, análista marketing bele foti desizaun estratéjika hodi fahe atensaun espesífiku ba kategoria kliente sira. Tuir mai mak detallu ba kategoria cluster ida-idak no implikasaun negósio nian:

- **Cluster 1 (Kliente VIP):** Kliente sira ne'ebé iha rendimentu anual aas no puntu gastu mós aas tebes. Grupu ne'e sai nu'udar objetivu prinsipál empreza nian, ne'ebé presiza simu tratamentu eskuzivu, programa lealdade (*loyalty program*), no promosaun produktu premium hodi mantein sira nia satisfasaun.
- **Cluster 2 (Kliente Standar):** Kliente ho rendimentu normal no puntu gastu iha nivel moderadu. Sira ne'e mak baze solidu ba transasaun diáriu negósio nian, ne'ebé kontribui ba estabilidade rendimentu empreza iha tempu naruk.
- **Cluster 3 (Kliente Joven):** Grupu kliente ho rendimentu ki'ik maibé iha puntu gastu ne'ebé aas. Sira ketak barak liu mak joven ka kliente foun ne'ebé gosta sosa produktu bazeia ba trend; tan ne'e, kampanha marketing dijital ne'ebé flexible no desconto atrai sira di'ak liu.

- **Cluster 4 (Kliente Potensial):** Kliente sira ne'ebé iha rendimentu no puntu gastu iha nivel moderadu. Sira iha poténsiu boot atu sa'e ba kategoria VIP se empreza fornese servisu no rekomendasaun produktu ne'ebé adekuadu.

8.1 Implemetasaun Estratéjia Marketing

Implementasaun husi sistema segmentasaun ne'e lori mudansa significativa ba dalan ne'ebé empreza fahe publicidade. Ho dadus ne'ebé agrupadu ona, departamentu marketing la gasta osan arbiru. Estratéjia ne'ebé bele foti inklui:

- **Personalizasaun Kampanha:** Hatete sai produktu tuir kliente nia gostu no kategoria cluster hodi hasae taxa konversaun.
- **Efisiénsia Rekursu Finanseiru:** Evita gastu osan arbiru ba marketing jeral ne'ebé la iha tarjetu klaru.
- **Fidelizasaun Kliente:** Fó atensaun barak liu ba kliente VIP no Potensial hodi kria relasaun naruk.

9 Protótipu

Hodi halo protótipu ne'e bele funsiona ho interativu no fasil atu uza husi análista negósiu, desenvolve ona aplikasaun web ida hodi uza libray *Streamlit* iha Python. Aplikasaun ne'e fornese interface gráfica (GUI) ne'ebé moos, iha ne'ebé fahe ba painel input dadus kliente foun nian no painel rezultadu prediksaun automatika.

Funsaun xave iha aplikasaun ne'e mak *Input no Prevé Kliente Foun*, ne'ebé husu utente atu hatama variavel sira hanesan Jéneru (*Gender*),

Idade, Rendimentu Anual (*Annual Income*), no Pontu Gastu (*Spending Score*).


Hanesan ezemplu testu konkretu iha sistema:

- **Dadus Input:** Feto (*Female*), Idade = 36.00, Rendimentu = \$90k, no Puntu Gastu (*Spending Score*) = 80.00.
- **Rezultadu Prediksaun:** Modelu prosesa dadus no hatudu kedas katak kliente ne'e tama iha kategoria **Kliente Potensial** (Cluster 4), ho nune'e facilita tomad6-desizaun marketing hodi f6 alvu kampanha ne'eb6 loos tuir tarjetu.

Input no Prev6 Kliente Foun

J6neru (Gender): Female
 Age: 36.00
 Annual Income (\$): 80.00
 Spending Score (1-100): 90.00

Rezultadu Prediksaun K-Means (PCA): Kliente foun ne'e tama ba **Kliente Potensial**



Kualidade Fahe Cluster (PCA Space)

Silhouette Score (Model K=4)
0.4164

Figure 6: Interf6s Prot6tipu Aplikasaun Streamlit

10 Konkluzau

Implementasaun conjunta husi algoritmu *K-Means Clustering* no *Principal Component Analysis (PCA)* ne'eb6 integradu ho di'ak iha aplikasaun web *Streamlit* ne'e f6 kbiit no vantajen boot tebes ba empreza no an6lista marketing. Sistema ne'e la'os de'it facilita prosesu segmentasaun kliente ho efektivu no automatizadu, maib6 m6s ajuda tebes

an6lista sira hodi foti desizaun marketing ne'eb6 loos tuir tarjetu. Liuhusi funsionamentu interativu no akuradu, aplikasaun m6s permiti atu halo prediksaun ba kategoria kliente foun ho lalais, hodi nune'e bele hasae efisi6nsia servisu no optimiza rendimentu empreza nian iha futuru.

11 Limitasaun

Maski projeta no implementasaun husi sistema segmentasaun kliente bazeia ba *K-Means* no *PCA* ne'e produz ona rezultadu ne'eb6 efektivu no v6lidu, maib6 iha m6s limitasaun balun ne'eb6 presiza meniona hodi sai nu'udar pontu refer6nsia ba desenvimentu iha futuru:

- **Flexibilidade Total Cluster (*K*):** Maski an6lise *Elbow Method* no *Silhouette Score* hatudu katak $K = 4$ mak 6ptimu ba dataset ne'e, iha futuru sistema bele dezenvolve hodi permite utente hili total cluster K ne'eb6 flexible tuir presiza ka objetivu espes6fiku neg6siu nian.
- **Karakter6stika Dataset Simulativu:** Dadus ne'eb6 uza iha projetu ne'e bazeia de'it ba dadus simulasau nian (*Mall Customers dataset*), ne'eb6 la refleta kondisaun re6l no kompleksidade husi transasaun kom6rsiu di6riu iha mundu neg6siu laran.
- **Falta Variavel Seluk:** Modelu foka de'it ba variavel (rendimentu no pontu gastu), enquanto iha mundu re6l, iha m6s fatores seluk hanesan ist6ria sosa produktu no frequ6nsia vizita ne'eb6 bele influ6nsia segmentasaun kliente nian.